AVA-I — Estudo de UX e avaliação com LLM-as-a-judge

Oct 25, 2026 · @Nicolas Pietro

Resumo executivo

O AVA-I tem uma base visual coesa (tema escuro, tipografia limpa), mas hoje funciona como um conjunto de formulários: as telas não mostram progresso, não guiam o próximo passo e escondem o estado do sistema. A proposta é tratar o redesign e a avaliação como um único ciclo: agentes LLM com personas usam o site (no molde do UXAgent), um LLM juiz pontua os rastros com rubricas fixas, e ferramentas determinísticas (Lighthouse, axe-core) medem performance e acessibilidade.

Prioridades, em ordem:

1. **Mostrar progresso e o próximo passo** — Início vira um painel pessoal ("continuar de onde parei", acerto recente, erros a revisar).
2. **Corrigir a hierarquia de ações na seleção de PDFs** — hoje o botão mais visível é o secundário ("Revisar meus erros") e o principal aparece desabilitado sem explicação.
3. **Tornar o Painel interpretável** — unidades, escala do foco, formato pt-BR e gráficos com eixo e legenda.
4. **Dar visibilidade ao processamento** — upload, indexação RAG e câmera ligada precisam de estado visível.
5. **Performance percebida** — geração de questões em streaming com pré-busca da próxima, visão computacional num Web Worker e carregamento sob demanda.

A avaliação compara a versão atual (A) com a redesenhada (B) por taxa de sucesso nas tarefas, passos até concluir, notas do juiz por heurística e SUS respondido pelos agentes.

Referencial: o que o UXAgent ensina para o AVA-I

O UXAgent (Lu et al., arXiv:2504.09407) gera milhares de personas, coloca um agente LLM para navegar num site real e entrega rastros de ação, rastros de raciocínio (um "think-aloud" sintético), questionário pós-estudo e entrevista com o agente. A posição dos autores é explícita: o agente serve de **estudo piloto**, não substitui participantes humanos.

Componente do UXAgent	Como funciona no paper	Adaptação no AVA-I
Persona Generator	Uma persona-semente + distribuição demográfica; cada nova persona usa uma anterior como exemplo para variar	Semente = estudante autodidata; distribuir por objetivo (prova, concurso, revisão), familiaridade digital, dispositivo e necessidade de acessibilidade
Fast Loop (perceive → plan → act)	Percepção converte o DOM simplificado em texto; o planejamento atualiza um plano curto; a ação executa um clique, digitação, hover ou seleção	Mesmo esquema, com Playwright sobre o Angular rodando localmente
Slow Loop (reflect + wonder)	Reflexão gera insights de alto nível; "wonder" gera pensamentos soltos para realismo	Manter a reflexão (gera as falas de frustração úteis ao juiz); "wonder" é opcional
Memory Stream	Memórias pontuadas por importância, relevância e recência	Manter; importa para sessões longas de questionário
Universal Browser Connector	DOM podado ao visível; clicável = controle nativo, `href`, `onclick`, papel ARIA ou `cursor: pointer`; IDs semânticos estáveis	Se o agente não acha um controle, isso já é achado de acessibilidade (semântica fraca)
Screenshot opcional	Texto puro por padrão; captura de tela quando se avalia layout	**Ligar sempre**: o objetivo aqui é justamente o visual
Result Viewer + entrevista	Tabela de execuções, replay passo a passo, entrevista em qualquer instante	Substituir o revisor humano pelo LLM juiz, que lê rastros e capturas

Limites que o paper declara e que viram ameaças à validade do TCC: os 16 pesquisadores do estudo deram confiança baixa aos dados (média 0,63 numa escala de −2 a +2) e discordaram que agentes substituem humanos (−0,44); alguns viram comportamentos "que usuários reais não fariam"; e o trabalho não compara quantitativamente agentes e humanos. O AgentA/B (arXiv:2504.09723) reforça que

agentes são mais focados no objetivo e exploram menos que pessoas, e Guerino et al. (arXiv:2506.16345) encontram só 21,2% de sobreposição entre GPT-4o e especialistas em heurísticas de Nielsen, com bom desempenho em estética e fraco em controle do usuário.

Consequência prática: como o AVA-I será avaliado sem humanos, a validade precisa vir de outro lugar — defeitos semeados de propósito, concordância entre juízes e métricas determinísticas (seção de protocolo).

Diagnóstico heurístico das telas atuais

Os problemas mais graves estão na seleção de PDFs e no Painel: são as telas onde o estudante decide o que fazer e entende o resultado. Severidade na escala de Nielsen (0 a 4); esta é uma inspeção manual pelas capturas, que serve de linha de base para comparar com o que o juiz LLM encontrar.

Tela	Problema observado	Heurística	Sev.
Seleção de PDFs	“Revisar meus erros” tem o maior contraste da tela; “Questionário” (ação principal) aparece apagado	Consistência e padrões	3
Seleção de PDFs	Botões desabilitados sem dizer por quê (falta “selecione ao menos 1 PDF”)	Visibilidade do estado	3
Seleção de PDFs	Checkboxes quase invisíveis no fundo escuro	Acessibilidade (contraste)	3
Painel	“87.3 foco médio” sem escala; “1.8 min” com ponto em vez de vírgula; “vezes no celular” ambíguo	Correspondência com o mundo real	3
Painel	Gráfico de foco sem eixo Y, sem legenda para azul vs. âmbar, eixo X com “0” e “1”	Reconhecer em vez de lembrar	3
Painel	Grade de 7 cartões com um buraco na segunda linha; métricas sem comparação com sessão anterior	Estética e design minimalista	2
Materiais	“X” de excluir cadeira colado na seta de expandir; sem confirmação visível	Prevenção de erros	3
Materiais	Linha recolhida não mostra quantos PDFs há nem se estão indexados	Visibilidade do estado	2

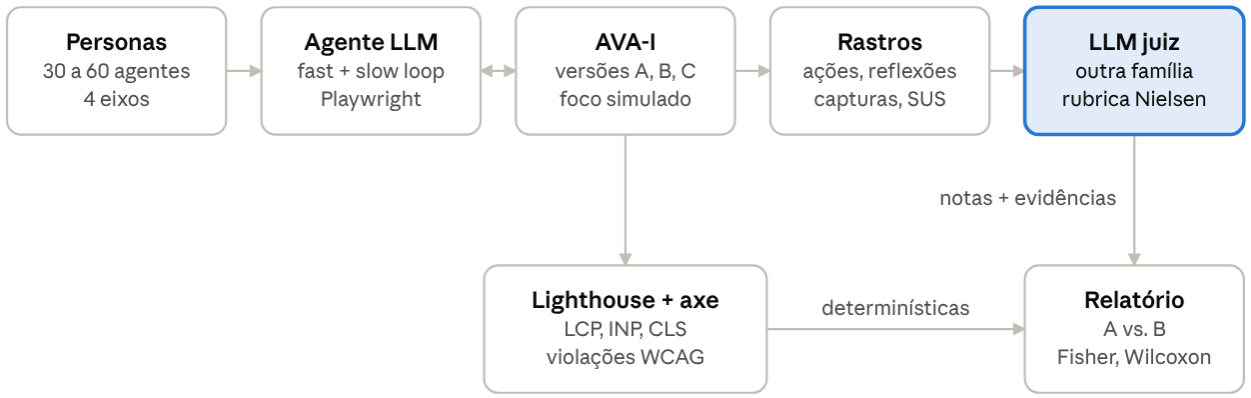
Tela	Problema observado	Heurística	Sev.
Materiais	A descrição promete “questão de exemplo”, mas o recurso não aparece na tela	Visibilidade do estado	2
Estudar	Cartões só com uma letra e cores sem significado (verde, oliva, mostarda) fora da paleta azul	Estética e design minimalista	2
Estudar	Rótulo “QUESTIONÁRIO” numa tela chamada Estudar, que também leva a material e revisão	Consistência e padrões	1
Início	Três cartões sem sinal de clique e sem dado do usuário; metade da tela vazia	Visibilidade do estado	2
Todas	Sem marca/logo no topo; item ativo do menu marcado só por negrito	Reconhecer em vez de lembrar	1
Todas	Texto secundário cinza sobre quase-preto, provavelmente abaixo de 4,5:1 (confirmar com axe-core)	Acessibilidade (WCAG 1.4.3)	2
Sessão de estudo	O monitoramento por câmera não tem indicador de estado nas telas vistas	Visibilidade + privacidade	3

O que já funciona: tema escuro consistente, tipografia legível, foco de teclado visível no menu (o contorno branco em “Materiais”), e o fluxo cadeira → PDFs → modo é curto.

Protocolo de avaliação automatizada

O protocolo roda a mesma bateria de agentes nas versões A (atual) e B (redesenhada) e compara as duas; o juiz nunca dá nota a uma versão isolada sem a outra como referência.

Agentes usam o site; um juiz de outra família pontua os rastros



pipeline de avaliação · agente, juiz e ferramentas determinísticas

O agente e o site trocam ações e respostas; os rastros vão ao juiz, e as métricas de Lighthouse e axe-core entram no relatório sem passar pelo LLM.

Personas

Semente: estudante autodidata que envia os próprios PDFs. Distribuição sugerida para 30 a 60 agentes, balanceada entre os eixos:

- **Objetivo:** prova da graduação na semana · concurso de longo prazo · revisão casual
- **Familiaridade digital:** alta · média · baixa
- **Contexto:** desktop com tempo · notebook com pressa (estuda à noite depois do trabalho)
- **Acessibilidade:** sem restrição · baixa visão (exige zoom de 200%) · só teclado

Tarefas

1. Criar a cadeira “Redes de Computadores” e enviar dois PDFs.
2. Gerar um questionário com os dois PDFs e responder cinco questões.
3. Revisar as questões erradas.
4. Gerar um material de estudo de um PDF.
5. No Painel, dizer qual material tem o pior acerto e quanto tempo foi estudado.
6. Excluir uma cadeira criada por engano (testa prevenção de erro).

A câmera não existe para o agente: injete um fluxo sintético de eventos de foco (ex.: um “celular” no minuto 3) por uma flag de teste, para o Painel ter dados e o indicador de câmera aparecer.

O juiz

Use um modelo de família diferente do agente, para reduzir o viés de o modelo preferir o próprio texto. O juiz recebe, por execução: persona, tarefa, rastro de ações, rastro de reflexões e as capturas de tela de cada passo. Ele devolve JSON com:

- `sucesso` (sim / parcial / não) e o passo em que travou
- uma nota de 0 a 4 por heurística de Nielsen, cada uma com a evidência (passo + elemento)
- uma nota visual de 1 a 5 para hierarquia, contraste, densidade e apelo, a partir das capturas
- a lista de problemas, cada um com severidade e uma sugestão de correção — pontuada por *acionabilidade*, como no UXBench (arXiv:2606.16262)

Métricas

Métrica	Fonte	Compara A vs. B
Taxa de sucesso por tarefa	Juiz + estado final da página	Teste exato de Fisher
Passos até concluir	Rastro de ações	Mann-Whitney + d de Cohen
Cliques em elemento não clicável	Erros do conector	Contagem
SUS respondido pelo agente	Questionário pós-tarefa	Diferença de médias (limiar 68)
Nota por heurística	Juiz	Wilcoxon pareado por tarefa
Performance (LCP, INP, CLS)	Lighthouse	Valor absoluto vs. meta
Violações WCAG	axe-core	Contagem por severidade

Como validar sem humanos

1. **Defeitos semeados:** crie uma variante C com cerca de 10 problemas conhecidos (botão sem rótulo, contraste baixo, exclusão sem confirmação, unidade faltando). A revocação do juiz sobre eles é a sua medida de acurácia.
2. **Concordância entre juízes:** dois modelos diferentes pontuam as mesmas execuções; reporte κ de Cohen ou α de Krippendorff.
3. **Estabilidade:** repita cada execução 3 vezes com temperatura fixa e reporte a variância.

4. **Âncora determinística:** onde axe-core e Lighthouse medem a mesma coisa que o juiz (contraste, rótulos), compare os dois.

Plano de redesign

A direção é sair de “formulários num fundo escuro” para um app que reage ao estudante: cada tela mostra onde ele está, o que melhorou e o que fazer agora. A paleta continua escura, com o azul como única cor de ação; verde, âmbar e vermelho ficam reservados para acerto, atenção e erro.

Início → painel pessoal

- Cartão grande “Continuar: Redes · snmpv3” com um botão, levando direto à última sessão.
- Faixa com três números da semana: minutos estudados, acerto, erros pendentes de revisão.
- Sequência de dias estudados (streak) discreta, sem tom infantil.
- Primeiro acesso: estado vazio em 3 passos (criar cadeira → enviar PDF → primeiro questionário) no lugar dos cartões estáticos.

Estudar → cartões com conteúdo

- Capa do cartão = miniatura da primeira página do PDF mais recente, no lugar da letra solta.
- Rodapé do cartão: nº de PDFs, anel de acerto, “último estudo há 2 dias”.
- Cores das cadeiras derivadas do azul (tons), ou escolhidas pelo usuário na criação.
- Rótulo da página muda de “QUESTIONÁRIO” para “ESTUDAR”.

Seleção de PDFs → escolha guiada

- Cada linha mostra miniatura, nº de páginas, acerto naquele PDF e um selo “3 erros” quando houver.
- Os três modos viram um controle segmentado (Questionário · Material · Revisar erros) acima da lista, e um único botão primário fixo no rodapé: “Começar com 2 PDFs”.
- Botão desabilitado explica o motivo logo abaixo; “Revisar erros” some ou desabilita quando não há erros.
- Checkbox com borda visível e a linha inteira clicável.

Questionário (tela não enviada; propostas gerais)

- Barra de progresso da sessão e contador de acertos ao vivo.

- Resposta com retorno imediato: certo/errado, explicação e o trecho do PDF de onde veio (página citada pelo RAG) — isso também dá confiança na questão gerada.
- Atalhos 1–4 para alternativas e Enter para avançar.
- Indicador fixo “câmera ligada · foco ativo” com opção de pausar.

Materiais → gestão com estado

- Área de arrastar e soltar PDFs, com barra de envio e status por arquivo: enviando → indexando → pronto.
- Linha recolhida mostra “2 PDFs · pronto”.
- Excluir vai para um menu “⋯” longe da seta, com confirmação ou um toast “Desfazer” por 5 s.
- Botão “Gerar questão de exemplo” visível em cada PDF, como a descrição promete.

Painel → leitura em 5 segundos

- Formato pt-BR e unidades humanas: “1 min 48 s”, “foco 87/100”, “2 distrações com celular”.
- Cada métrica com variação contra a sessão anterior (▲ / ▼).
- Foco como linha no tempo da sessão, com marcadores nos momentos de celular, eixo Y de 0 a 100 e legenda.
- Acerto por material ordenado do pior para o melhor, com a cor indicando a faixa.
- Uma frase de leitura gerada no topo (ex.: “Seu acerto em Segurança está em 50%; revise os 4 erros”).

Microinterações (em todo o app)

- Elevação leve no hover de cartões e cursor de clique em tudo que é clicável (o conector do UXAgent também usa `cursor: pointer` para detectar o que é clicável).
- Transições de rota com a View Transitions API; esqueletos de carregamento no lugar de telas vazias.
- Toasts para ações concluídas; animação de acerto curta.
- Tudo isso respeitando `prefers-reduced-motion`.

Plano de performance

O maior ganho percebido está na espera pela questão gerada, não no carregamento das páginas: o “fluxo contínuo” de questões só parece contínuo se a próxima já estiver pronta. Metas: LCP abaixo de 2,5 s, INP abaixo de 200 ms, CLS abaixo de 0,1, e a primeira questão visível em menos de 1 s depois do clique (o limite de Nielsen que você já cita).

Camada	Mudança	Efeito esperado
Back-end (FastAPI + LangChain)	Fila de pré-geração: enquanto o aluno responde a questão N, gerar N+1 e N+2 em segundo plano	Troca de questão quase instantânea
Back-end	Resposta em streaming (SSE) para material de estudo, com o texto aparecendo aos poucos	Tempo até o primeiro conteúdo cai de segundos para décimos
Back-end (ChromaDB)	Cache dos trechos recuperados por conjunto de PDFs da sessão	Menos consultas repetidas ao índice
Front (visão computacional)	MediaPipe/YOLO num Web Worker, com onnxruntime-web em WebGPU e WASM como reserva; taxa de inferência reduzida	A UI não trava durante a sessão; menos INP
Front	Carregar o modelo ONNX só ao iniciar uma sessão, com indicador de carregamento	Início, Materiais e Painel ficam leves
Front (Angular 19)	Rotas com `loadComponent`, blocos `@defer` para os gráficos do Painel, signals com `OnPush`	Pacote inicial menor; menos ciclos de detecção
Front	Miniaturas de PDF geradas no servidor uma vez, servidas em WebP com `NgOptimizedImage`	Cartões com capa sem custo de renderizar PDF no navegador
Front	Esqueletos com altura fixa no lugar de telas vazias	CLS perto de zero
Build	`budgets` no `angular.json` que quebram o build ao estourar o tamanho	Impede regressão

Meça antes e depois com Lighthouse em modo CI na mesma máquina, 5 execuções por página, mediana; e registre no `GeracaoLog` o tempo de geração por questão para ter a distribuição real.

Roadmap

1. **Linha de base:** rodar Lighthouse + axe-core e a bateria de agentes na versão A; guardar rastros e notas.
2. **Validar o juiz:** construir a variante C com defeitos semeados; medir revocação e concordância entre dois juízes antes de confiar nas notas.
3. **Correções de severidade 3:** seleção de PDFs, Painel, exclusão em Materiais, indicador de câmera.
4. **Performance:** pré-geração de questões, streaming, Web Worker, `@defer`.
5. **Redesign visual:** Início como painel pessoal, cartões com conteúdo, microinterações.
6. **Comparação final:** mesma bateria na versão B; testes estatísticos da seção de protocolo.

Ameaças à validade

- **Agente ≠ humano:** agentes exploram menos e erram de forma diferente (AgentA/B; UXAgent). Reporte os resultados como "estudo piloto simulado", não como evidência de usabilidade para pessoas.
- **Juiz enviesado:** preferência pelo próprio modelo, pela versão mais longa ou pela primeira apresentada. Mitigar com família diferente, ordem A/B aleatória e rótulos cegos.
- **Circularidade:** se o mesmo LLM sugere o redesign e depois o avalia, a melhora pode ser artefato. Separe quem propõe de quem julga.
- **Câmera simulada:** o foco injetado não testa o MediaPipe/YOLO real; isso fica fora do escopo desta avaliação.
- **Relato:** siga o checklist de arXiv:2602.05128 (modelos e versões, prompts, temperatura, nº de execuções, custo).

Referências

- Lu et al. *UXAgent: A System for Simulating Usability Testing of Web Design with LLM Agents.* arXiv:2504.09407
- Lu et al. *UXAgent: An LLM-Agent-Based Usability Testing Framework for Web Design.* arXiv:2502.12561
- *AgentA/B: Automated and Scalable Web A/B Testing with LLM Agents.* arXiv:2504.09723
- Guerino et al. *Can GPT-4o Evaluate Usability Like Human Experts?* arXiv:2506.16345

- *Generating Automatic Feedback on UI Mockups with Large Language Models* (CHI '24). arXiv:2403.13139
- *UXBench: Measuring the Actionability of LLM-Generated UX Critiques.* arXiv:2606.16262 — conferir se o ID resolve
- *Reporting and Reviewing LLM-Integrated Systems in HCI.* arXiv:2602.05128 — conferir se o ID resolve
- *Systematic Literature Review of Automation and AI in Usability Issue Detection.* arXiv:2504.01415