

**ANÁLISE COMPORTAMENTAL E
AVALIAÇÃO FORMATIVA:
PROPOSTA DE UM AMBIENTE
VIRTUAL DE APRENDIZAGEM
INTELIGENTE**

NICOLAS PIETRO MOURA DA SILVA

Proposta de Trabalho de Conclusão
submitted to the Pontifical Catholic
University of Rio Grande do Sul in partial
fulfillment of the requirements for the
degree of Bachelor in Computer Science.

Advisor: Prof. Otávio Parraga

ANÁLISE COMPORTAMENTAL E AVALIAÇÃO FORMATIVA: PROPOSTA DE UM AMBIENTE VIRTUAL DE APRENDIZAGEM INTELIGENTE

RESUMO

O ensino remoto e híbrido ampliou o uso de Ambientes Virtuais de Aprendizagem (AVAs — plataformas digitais, como Moodle ou Google Classroom, que reúnem materiais, atividades e comunicação entre professores e alunos pela internet), mas o estudo autônomo nesses ambientes enfrenta dois problemas recorrentes: a dispersão da atenção durante a leitura de materiais didáticos e a ausência de mecanismos que verifiquem, de forma imediata, o que o aluno realmente compreendeu. Este trabalho propõe um AVA inteligente composto por três módulos: (i) recebimento dos materiais do professor e geração automática de questões formativas (perguntas criadas ao longo do estudo, com o objetivo de ajudar o aluno a perceber o que entendeu — e não de atribuir nota) por meio de *Retrieval-Augmented Generation* (RAG — técnica que faz um modelo de inteligência artificial criar perguntas ancoradas diretamente no texto do próprio professor, reduzindo o risco de informações incorretas) sobre um *Large Language Model* (LLM — modelo de linguagem de grande escala, como o ChatGPT ou o Claude, capaz de gerar texto em linguagem natural); (ii) acompanhamento do engajamento visual do estudante por visão computacional (a área da inteligência artificial que permite ao computador interpretar imagens e vídeos) executada integralmente no navegador do aluno, sem transmitir nenhum vídeo ao servidor; e (iii) painéis analíticos para o docente, que cruzam os indicadores de atenção do aluno com seu desempenho nas questões. A proposta apresenta o problema, o referencial teórico, a arquitetura do sistema, a metodologia, o plano de avaliação — condicionado à aprovação do Comitê de Ética em Pesquisa — e o cronograma de execução.

Palavras-Chave: ambiente virtual de aprendizagem, modelos de linguagem, geração aumentada por recuperação, visão computacional, engajamento, avaliação formativa, LGPD.

BEHAVIOURAL ANALYSIS AND FORMATIVE ASSESSMENT: A PROPOSAL FOR AN INTELLIGENT VIRTUAL LEARNING ENVIRONMENT

ABSTRACT

Remote and hybrid teaching have expanded the use of Virtual Learning Environments (VLEs — digital platforms that gather materials, activities and communication between teachers and students over the internet), but autonomous study within them faces two recurring problems: attention dispersion during reading and the absence of mechanisms to immediately verify what students have actually understood. This work proposes an intelligent VLE composed of three modules: (i) ingestion of the instructor's material and automatic generation of formative questions (questions created throughout the study session to help students identify what they have understood, not to assign grades) through Retrieval-Augmented Generation (RAG — a technique that makes an artificial intelligence model generate questions grounded directly in the instructor's own text, reducing the risk of incorrect information) over a Large Language Model (LLM — a large-scale language model, such as ChatGPT or Claude, capable of generating natural language text); (ii) monitoring of the student's visual engagement through computer vision (the area of artificial intelligence that enables computers to interpret images and video) executed entirely in the student's browser, with no video transmission to the server; and (iii) analytical dashboards for the instructor, crossing student attention indicators with performance on the formative questions. The proposal presents the problem, theoretical background, system architecture, methodology, evaluation plan — subject to Research Ethics Committee approval — and the execution schedule.

Keywords: virtual learning environment, large language models, retrieval-augmented generation, computer vision, engagement, formative assessment, data protection.

LIST OF TABLES

Table 6.1 – Principais riscos do projeto e mitigações previstas.	23
Table 7.1 – Cronograma de TC2 (2026/2).	24

LIST OF ACRONYMS

AVA – Ambiente Virtual de Aprendizagem
CEP – Comitê de Ética em Pesquisa
EAR – Eye Aspect Ratio (Razão de Aspecto do Olho)
IA – Inteligência Artificial
ITS – Intelligent Tutoring System (Sistema de Tutoria Inteligente)
LGPD – Lei Geral de Proteção de Dados
LLM – Large Language Model (Modelo de Linguagem de Grande Escala)
PLN – Processamento de Linguagem Natural
POC – Prova de Conceito
RAG – Retrieval-Augmented Generation (Geração com Apoio de Recuperação)
SPA – Single Page Application (Aplicação de Página Única)
SUS – System Usability Scale (Escala de Usabilidade do Sistema)
TCLE – Termo de Consentimento Livre e Esclarecido
VC – Visão Computacional

CONTENTS

1	INTRODUÇÃO	9
1.1	OBJETIVOS	10
2	REFERENCIAL TEÓRICO	11
2.1	DISPERSÃO DA ATENÇÃO E METACOGNIÇÃO NO ESTUDO REMOTO	11
2.2	SISTEMAS DE TUTORIA INTELIGENTE, LLMS E RAG	12
2.3	MEDIÇÃO VISUAL DE ENGAJAMENTO	12
2.4	PRIVACIDADE, LGPD E PROCESSAMENTO NO COMPUTADOR DO ALUNO	13
3	PROPOSTA	14
3.1	VISÃO GERAL DO SISTEMA	14
3.2	QUESTÕES DE PESQUISA	14
4	ARQUITETURA E INTEGRAÇÃO TECNOLÓGICA	16
4.1	NAVEGADOR DO ALUNO — INTERFACE VISUAL	16
4.1.1	TRATAMENTO DA LIMITAÇÃO DE HARDWARE	17
4.2	SERVIDOR — PROCESSAMENTO E ARMAZENAMENTO	17
4.3	MÓDULO DE GERAÇÃO DE QUESTÕES (RAG)	18
4.4	FLUXO DE DADOS	18
5	METODOLOGIA	19
5.1	ETAPA 1 — REVISÃO COMPLEMENTAR E ESPECIFICAÇÃO	19
5.2	ETAPA 2 — SERVIDOR E GERAÇÃO DE QUESTÕES	19
5.3	ETAPA 3 — INTERFACE E VISÃO COMPUTACIONAL	19
5.4	ETAPA 4 — AVALIAÇÃO EXPERIMENTAL	19
6	AVALIAÇÃO	20
6.1	CONSIDERAÇÕES ÉTICAS	20
6.2	DESENHO EXPERIMENTAL	20
6.3	PARTICIPANTES	21
6.4	INDICADORES	21
6.5	ANÁLISE ESTATÍSTICA	21
6.6	AVALIAÇÃO DO PAINEL PELO DOCENTE	22

6.7	RISCOS E MITIGAÇÕES	23
7	CRONOGRAMA	24
7.1	MARCOS DE DECISÃO	24
8	CONSIDERAÇÕES FINAIS.....	25
	REFERENCES	26

1. INTRODUÇÃO

A transformação digital do ensino, acelerada pela pandemia de COVID-19, tornou os Ambientes Virtuais de Aprendizagem (AVAs) infraestrutura padrão em cursos presenciais, híbridos e remotos [HBF19, Bat19]. Esse movimento ampliou o acesso ao material didático, mas também transferiu para o estudante uma responsabilidade maior: cabe a ele decidir quando, como e com que profundidade estudar. Nesse contexto, a Inteligência Artificial (IA) — em particular, técnicas de Processamento de Linguagem Natural (PLN, o campo da IA que ensina o computador a entender e gerar texto em idiomas humanos) e de Visão Computacional (VC, o campo da IA que permite ao computador interpretar imagens) — tornou-se parte funcional de plataformas educacionais, ao apoiar a personalização do ensino e o acompanhamento da atenção [Van11, HBF19].

O estudo autônomo nesses ambientes enfrenta, contudo, dois obstáculos persistentes. O primeiro é a *dispersão da atenção*: a troca constante entre o estudo e estímulos externos — em especial o *smartphone* (celular de tela sensível ao toque com acesso à internet) — aumenta o esforço mental necessário para aprender e prejudica a fixação do conteúdo [KDB17, Bat19]. O segundo é a *passividade do material didático*: ler um PDF ou *slide* sem nenhuma verificação imediata do que foi absorvido gera a ilusão de aprendizado, sem garantia de retenção real [DDD17].

Do lado do professor, dois problemas se somam. O primeiro é a *dificuldade de escalar a avaliação formativa*: criar exercícios contínuos a partir dos próprios materiais exige tempo e raramente é viável durante o semestre inteiro. O segundo é a *cegueira analítica*: o docente recebe as notas das provas, mas não consegue identificar em quais partes do material os alunos perderam a atenção ou qual conteúdo gerou mais dúvidas antes da avaliação. Sistemas de Tutoria Inteligente (*Intelligent Tutoring Systems*, ITS — programas que adaptam o ritmo e o conteúdo de ensino ao estado de conhecimento do aluno, como se fosse uma tutoria individual) endereçam parte desses problemas e produzem ganhos de aprendizagem comparáveis aos de tutoria humana individual [Van11]. O surgimento dos *Large Language Models* (LLMs — modelos de linguagem de grande escala treinados em enormes volumes de texto, que conseguem responder perguntas, resumir documentos e gerar novos textos) [BMR⁺20, ZZL⁺23] e da arquitetura de *Retrieval-Augmented Generation* (RAG — técnica que, antes de gerar uma resposta, faz o modelo consultar uma fonte de referência confiável para se basear nela) [LPP⁺20, GXG⁺23] torna viável, hoje, criar questões formativas ancoradas no material do próprio professor, com risco reduzido de informações incorretas — algo inviável nos ITSs baseados em regras manuais.

Este trabalho propõe uma plataforma que une essas duas frentes: geração automática de avaliações formativas a partir do material do professor e monitoramento local da atenção visual do estudante, com os resultados reunidos em painéis analíticos para o

docente. O restante do documento apresenta o referencial teórico (Capítulo 2), a proposta e suas questões de pesquisa (Capítulo 3), a arquitetura (Capítulo 4), a metodologia (Capítulo 5), o plano de avaliação (Capítulo 6) e o cronograma (Capítulo 7).

1.1 Objetivos

O objetivo geral é propor, desenvolver e avaliar um Ambiente Virtual de Aprendizagem Inteligente que integre (i) geração automática de questões formativas baseadas em RAG sobre o material do professor, (ii) cálculo local de indicadores de atenção visual do estudante no próprio navegador e (iii) um painel analítico (*dashboard*) para o docente, capaz de cruzar atenção e desempenho.

São objetivos específicos:

1. Revisar a literatura sobre ITS, RAG aplicada à educação e medição automática de atenção por VC.
2. Especificar a arquitetura da plataforma, considerando as limitações de *hardware* (equipamento físico do computador) do aluno e os requisitos de privacidade da Lei Geral de Proteção de Dados (LGPD — Lei nº 13.709/2018, que regula o uso de informações pessoais de brasileiros) [Bra18].
3. Implementar uma Prova de Conceito (PoC — uma versão funcional simplificada que demonstra que a ideia é viável) dos três módulos.
4. Validar a PoC com estudantes voluntários, com aprovação prévia do Comitê de Ética em Pesquisa (CEP) da PUCRS, usando métodos estatísticos adequados ao tamanho da amostra.

2. REFERENCIAL TEÓRICO

Este capítulo aprofunda os fundamentos que sustentam a proposta. A Seção 2.1 trata da autorregulação, da metacognição e da dispersão da atenção em ambientes digitais. A Seção 2.2 discute Sistemas de Tutoria Inteligente, LLMs e a técnica RAG. A Seção 2.3 aborda a medição automática de atenção por VC. A Seção 2.4 trata de privacidade e conformidade com a LGPD.

2.1 Dispersão da atenção e metacognição no estudo remoto

O estudo autônomo em ambientes digitais exige que o aluno seja capaz de planejar, monitorar e ajustar o próprio processo de aprendizagem — habilidade chamada de *autorregulação*. Um conceito central nesse contexto é a *metacognição* (do grego *meta*, “além de”, mais *cognição*, “pensamento”), definida por Flavell [Fla79] como a capacidade de o indivíduo perceber e controlar os próprios processos de raciocínio — em termos práticos, a habilidade de identificar o que se entendeu e o que ainda não.

A literatura indica que essa capacidade costuma ser superestimada em ambientes digitais. Kirschner e De Bruyckere [KDB17] reúnem evidências contra a noção do “nativo digital” capaz de realizar várias tarefas ao mesmo tempo: trocar constantemente entre o estudo e estímulos externos aumenta o custo mental de cada tarefa, eleva a chamada carga cognitiva (o esforço mental que o cérebro precisa dispender para processar informações) e reduz o desempenho. Bates [Bat19] descreve o *cyber-slacking* — o uso do dispositivo para fins não acadêmicos durante o estudo — e seus efeitos negativos sobre a memória de trabalho (a capacidade de manter e manipular informações por um curto período, como uma “mesa de trabalho” mental). Para tornar o engajamento mensurável, D’Mello, Dieterle e Duckworth [DDD17] propõem o arcabouço AAA (*Advanced, Analytic, Automated* — avançado, analítico e automatizado), que combina sinais comportamentais observáveis (postura, direção do olhar, interação com a interface) e inferências sobre estados afetivos para estimar, de forma contínua e sem interromper o aluno, o grau de envolvimento com a tarefa.

Desses trabalhos decorre a premissa central desta proposta: o *feedback* imediato (retorno instantâneo ao aluno sobre seu desempenho) e os pontos de verificação de compreensão funcionam como gatilhos metacognitivos — isto é, provocam o aluno a refletir sobre o próprio entendimento — permitindo que a dispersão seja percebida e corrigida antes de se converter em fracasso na avaliação final [DDD17, Van11].

2.2 Sistemas de Tutoria Inteligente, LLMs e RAG

Intelligent Tutoring Systems (ITS) são programas que adaptam o ritmo, a sequência e o conteúdo do ensino com base no que o aluno já sabe — funcionando como uma espécie de professor particular computadorizado. A meta-análise de VanLehn [Van11] (um tipo de estudo que combina os resultados de várias pesquisas anteriores para chegar a uma conclusão mais robusta) indica que ITSs com interação em granularidade fina (sistemas que respondem a cada passo do raciocínio do aluno, não apenas à resposta final) alcançam tamanho de efeito $d \approx 0,76$ sobre a aprendizagem. O d de Cohen — uma medida criada pelo estatístico Jacob Cohen [Coh88] para expressar o quanto uma intervenção altera um resultado, em unidades de desvio-padrão (uma medida de variação dos dados) — indica que valores próximos de 0,8 representam efeitos grandes, comparáveis aos da tutoria humana individual. Historicamente, porém, esses sistemas dependiam de bases de regras criadas manualmente por especialistas, o que tornava difícil adaptá-los a novos assuntos.

Os *Large Language Models* (LLMs) [BMR⁺20, ZZL⁺23] transformaram esse cenário ao permitir que conteúdo pedagógico — inclusive questões formativas — seja gerado a partir de instruções em linguagem natural, sem programação manual. Contudo, LLMs operados sem uma fonte de referência estão sujeitos a *alucinações*: podem gerar afirmações que soam verdadeiras, mas são incorretas. A arquitetura de *Retrieval-Augmented Generation* (RAG), proposta por Lewis et al. [LPP⁺20] e consolidada no levantamento de Gao et al. [GXG⁺23], mitiga esse risco: antes de gerar a resposta, o sistema recupera trechos relevantes de uma fonte confiável e os fornece ao modelo como contexto, fazendo com que a geração seja guiada pelo material de referência.

No fluxo RAG, o texto fonte é dividido em fragmentos menores (chamados de *chunks* em inglês, termo sem tradução padrão consagrada, que indica pedaços de texto de tamanho controlado) e convertido em representações vetoriais (*embeddings* — sequências de números que representam o significado do texto de forma que frases com sentido parecido fiquem “próximas” entre si no espaço matemático). Esses vetores ficam guardados em um banco vetorial; na hora de criar a questão, o trecho mais relevante é localizado e entregue ao LLM como contexto [GXG⁺23]. Isso torna a abordagem especialmente adequada à criação de avaliações formativas ancoradas em um material didático específico.

2.3 Medição visual de engajamento

A análise automática de atenção por VC se apoia em dois componentes principais: o rastreamento dos movimentos e estado dos olhos e a detecção de objetos no ambiente do estudante.

Ferramentas de rastreamento facial, como o arcabouço MediaPipe [LTN⁺19] (desenvolvido pelo Google e disponível gratuitamente), permitem estimar em tempo real a posição da cabeça e o estado dos olhos a partir de uma câmera comum, sem nenhum equipamento especializado. Seu componente *Face Mesh* [KAGG19] identifica 468 pontos faciais tridimensionais, é otimizado para rodar diretamente no navegador do computador e tem uso recorrente em pesquisas de engajamento educacional [AK24, DD25]. Sobre esses pontos calcula-se o *Eye Aspect Ratio* (EAR — Razão de Aspecto do Olho), proposto por Soukupová e Cech [SC16]: uma fórmula que compara a abertura vertical e a largura horizontal do olho, gerando um único número que indica se ele está aberto ou fechado — valores mais altos indicam olho aberto; valores próximos de zero, olho fechado ou semicerrado. Detectores de sonolência baseados nessa fórmula já foram amplamente validados [MdCMSL20]. Combinando EAR, pose da cabeça e direção estimada do olhar, é possível inferir se o estudante está olhando para a tela do material didático.

A detecção de *smartphones* no campo da câmera, por sua vez, é um indicador direto de *cyber-slacking*. Para isso utiliza-se o modelo YOLO (*You Only Look Once* — “você só olha uma vez”, em referência ao fato de o modelo precisar ver a imagem apenas uma única vez para identificar todos os objetos nela) [RDGF16], na versão YOLOv8 [JCQ23]. Essa versão oferece variantes “nano” (muito pequenas e leves) que podem rodar no próprio navegador por meio do ONNX Runtime Web (um motor de execução de modelos de IA que funciona diretamente no navegador, sem precisar de um servidor dedicado para os cálculos)¹. Uma limitação importante precisa ser reconhecida: rodar modelos de detecção de objetos no navegador depende do poder de processamento do computador do aluno e pode ser inviável em máquinas mais antigas ou modestas [JCQ23]. O Capítulo 4 trata explicitamente essa restrição.

2.4 Privacidade, LGPD e processamento no computador do aluno

O monitoramento por VC em contexto educacional é especialmente sensível: a imagem de vídeo de um estudante é um dado pessoal, protegido pela Lei Geral de Proteção de Dados (LGPD — Lei nº 13.709/2018, que regulamenta como empresas e instituições podem coletar, armazenar e usar informações pessoais de cidadãos brasileiros) [Bra18]. A literatura sobre IA educacional ética [HBF19, UNE21] recomenda o princípio de *privacy by design* (privacidade desde a concepção): incorporar a proteção de dados à arquitetura do sistema desde o início, em vez de tratá-la como um ajuste posterior ao desenvolvimento [Cav09]. Por isso, a proposta executa toda a visão computacional no próprio navegador do estudante: nenhum quadro de vídeo trafega pela rede, e o servidor recebe apenas métricas numéricas agregadas, conforme descrito no Capítulo 4.

¹<https://onnxruntime.ai/docs/tutorials/web/>

3. PROPOSTA

Este capítulo apresenta, de forma conceitual, o sistema a ser desenvolvido e as questões de pesquisa que orientarão sua avaliação. Os detalhes técnicos estão no Capítulo 4.

3.1 Visão geral do sistema

Propõe-se um Ambiente Virtual de Aprendizagem Inteligente (AVA-I), acessível pelo navegador sem necessidade de instalação, com três módulos integrados.

Módulo 1 — Geração de questões formativas (Docente). O professor envia os PDFs do material didático. O sistema extrai o texto, divide-o em trechos de tamanho controlado, converte cada trecho em uma representação vetorial numérica e disponibiliza tudo ao modelo de IA, via RAG, como fonte autoritativa. O modelo cria questões de múltipla escolha ancoradas em trechos específicos. O professor revisa cada questão — podendo ver exatamente o trecho do PDF que a originou —, aprova, edita ou descarta, e só então publica na plataforma.

Módulo 2 — Sessão de estudo inteligente (Discente). O estudante lê o material na plataforma. Ao final de cada seção, aparece uma questão formativa correspondente àquele trecho. As questões são criadas previamente, na etapa de preparação do material, evitando qualquer atraso ou custo adicional durante a sessão do aluno. Com consentimento, a câmera é usada localmente — no próprio navegador — para calcular indicadores de atenção (estado dos olhos, posição da cabeça e presença de celular no campo de visão). Nenhum vídeo é enviado ao servidor; apenas números são transmitidos.

Módulo 3 — Painel analítico (Docente). O professor visualiza, de forma agregada e sem identificar os alunos individualmente, em quais trechos do material a turma perdeu mais atenção, em quais questões houve mais erros e como atenção e desempenho se relacionam entre si. Esses dados apoiam a revisão e o aprimoramento do próprio material.

3.2 Questões de pesquisa

A avaliação da plataforma (Capítulo 6) é guiada por três questões de pesquisa.

QP1. O nível de atenção visual do estudante, medido pela plataforma, está positivamente associado ao seu desempenho nas questões formativas?

QP2. A inserção de questões formativas ao longo da leitura reduz a frequência de uso do celular durante o estudo?

QP3. A execução dos modelos de visão computacional no navegador do aluno preserva a usabilidade percebida da plataforma?

Para a QP3, adota-se como referência a pontuação 68 do *System Usability Scale* (SUS — um questionário padronizado de dez perguntas criado por Brooke [Bro96] para avaliar a facilidade de uso de sistemas digitais, em que a pontuação varia de 0 a 100). O valor 68 corresponde à média obtida em centenas de aplicações do questionário compiladas por Sauro [Sau11]: uma pontuação igual ou superior a esse valor indica que o sistema é, no mínimo, tão fácil de usar quanto a maioria dos sistemas digitais existentes. Bangor et al. [BKM08] oferecem faixas de interpretação complementares.

4. ARQUITETURA E INTEGRAÇÃO TECNOLÓGICA

A plataforma é organizada em três camadas que se comunicam. O critério arquitetural central é o *privacy by design* (Seção 2.4): o processamento de imagem ocorre integralmente no computador do aluno, e a rede transporta apenas dados numéricos agregados. A Figura 4.1 apresenta a visão geral.




Figure 4.1 – Visão geral da arquitetura. A câmera do aluno é processada inteiramente no navegador; apenas métricas numéricas chegam ao servidor.

4.1 Navegador do aluno — interface visual

A interface é desenvolvida em Angular¹ (uma ferramenta criada pelo Google para construir aplicações web organizadas e robustas), com TypeScript (uma versão do JavaScript — a linguagem padrão da web — que verifica erros automaticamente antes de o código ser executado, reduzindo falhas). É uma *Single Page Application* (SPA — aplicação que carrega uma única vez no navegador e atualiza apenas o conteúdo necessário, sem recarregar a página inteira, oferecendo uma experiência mais fluida, similar a um aplicativo de celular). No navegador do aluno, dois modelos de VC são executados:

- *MediaPipe Face Mesh* [LTN⁺19, KAGG19], para identificar 468 pontos do rosto em tempo real. Sobre esses pontos, calcula-se o EAR [SC16] (Razão de Aspecto do Olho) e estima-se a posição da cabeça, derivando a métrica *focusScore* (pontuação de foco): a proporção do tempo em que (i) o rosto está detectado, (ii) a cabeça está aproximadamente voltada para a tela e (iii) o EAR indica olhos abertos acima de um valor calibrado individualmente. Esse valor é definido numa calibração de 30 segundos no início de cada sessão — tempo suficiente para capturar vários ciclos de piscada e a postura habitual do estudante, sem ser longo o suficiente para ser inconveniente.

¹<https://angular.dev>

- *YOLOv8-nano* [RDGF16, JCQ23], um modelo de detecção de objetos em versão extremamente compacta (“nano”), exportado para o formato ONNX (Open Neural Network Exchange — um padrão aberto que permite compartilhar e executar modelos de IA em diferentes plataformas e ferramentas) e executado via *ONNX Runtime Web*, para identificar a presença de celular no campo de visão da câmera. Cada detecção gera um registro associado ao instante da sessão.

4.1.1 Tratamento da limitação de hardware

Rodar modelos de detecção de objetos diretamente no navegador exige um computador com capacidade de processamento razoável — o que nem todos os alunos têm. Para lidar com isso, adota-se a estratégia de *degradação graciosa*: quando o ambiente não suporta determinada funcionalidade, o sistema desativa apenas essa parte e mantém o restante funcionando normalmente. Na prática, ao iniciar, o sistema testa se o modelo YOLO consegue processar uma imagem de amostra em menos de 250 ms (milissegundos, ou seja, menos de um quarto de segundo). Esse limite equivale a quatro análises por segundo: frequência suficiente para detectar um episódio de uso de celular — que normalmente dura alguns segundos — e ao mesmo tempo leve o suficiente para não sobrecarregar o processador. O valor vem das recomendações clássicas de tempo de resposta de interfaces [Nie93], segundo as quais atrasos acima desse patamar tornam a interação perceptivelmente lenta. Caso o limite seja superado, ou se o navegador não dispuser das funcionalidades gráficas necessárias (WebGL/WebGPU — tecnologias que permitem ao navegador usar a placa de vídeo do computador para acelerar cálculos), o detector de celular é desativado automaticamente e a sessão prossegue apenas com a análise facial. O modo de operação é registrado, e sessões em modo degradado não entram no cálculo da QP2.

4.2 Servidor — processamento e armazenamento

O servidor é desenvolvido em Python com FastAPI² (uma ferramenta que facilita a criação de APIs — Application Programming Interfaces, interfaces de comunicação entre programas), adotado pelo suporte a operações simultâneas (assíncronas), o que é importante porque as respostas do modelo de IA podem demorar tempos variáveis. O servidor é responsável por: (i) gerenciar o acesso dos usuários e o histórico das sessões; (ii) receber as métricas numéricas agregadas enviadas pelo navegador — *nunca* vídeos; (iii) acionar o módulo de RAG para criar as questões; (iv) guardar no banco de dados (PostgreSQL —

²<https://fastapi.tiangolo.com>

sistema de banco de dados robusto e gratuito) os materiais, questões, sessões e respostas; e (v) fornecer os dados consolidados para o painel do professor.

4.3 Módulo de geração de questões (RAG)

O módulo é implementado com LangChain³ (uma ferramenta de código aberto que facilita a construção de aplicações com modelos de IA) [GXG⁺23]. Os PDFs passam por extração de texto, divisão em trechos e geração de representações vetoriais. Os vetores ficam indexados no ChromaDB⁴ (um banco de dados especializado em armazenar e buscar vetores, funcionando como uma biblioteca que encontra textos com significados parecidos mesmo que usem palavras diferentes). Para evitar que o volume de dados cresça indefinidamente, cada material é organizado em sua própria coleção isolada, e os vetores são calculados uma única vez no momento do envio; caso o crescimento comprometa o desempenho, bancos vetoriais dedicados podem ser usados no lugar do ChromaDB sem alterar o restante da arquitetura. A geração das questões é feita por um LLM acessado via API (uma interface de acesso remoto ao modelo), condicionado ao trecho recuperado, em dois cenários: *Restrito* (somente o trecho do PDF) e *Expandido* (o trecho do PDF acrescido de outros trechos relacionados, também recuperados do banco vetorial).

4.4 Fluxo de dados

1. O professor envia o PDF; o servidor extrai o texto, divide em trechos e os indexa no banco vetorial.
2. O módulo RAG cria as questões; o professor revisa e aprova antes da publicação.
3. O aluno inicia a sessão; o navegador ativa a análise facial e, se o computador suportar, o detector de celular.
4. A cada intervalo fixo, o navegador envia ao servidor um pacote com as métricas agregadas (instante, pontuação de foco, quantidade de eventos de celular e modo de operação).
5. Ao terminar uma seção, aparece a questão previamente aprovada; a resposta do aluno é registrada no servidor.
6. O painel do professor consulta o servidor, que cruza todas as informações e retorna os dados prontos para os gráficos.

³<https://www.langchain.com>

⁴<https://www.trychroma.com>

5. METODOLOGIA

O trabalho será desenvolvido em quatro etapas. A pesquisa é de natureza aplicada: um protótipo funcional será construído e avaliado com usuários reais para responder às questões de pesquisa do Capítulo 3.

5.1 Etapa 1 — Revisão complementar e especificação

Aprofundamento do referencial em três frentes: ITS com LLMs, medição automática de atenção em contexto educacional [DDD17, AK24, DD25] e aspectos legais da LGPD aplicados ao contexto educacional [Bra18]. Ao final, a especificação técnica do sistema é concluída para guiar as etapas seguintes.

5.2 Etapa 2 — Servidor e geração de questões

Construção do servidor com FastAPI, modelagem do banco de dados PostgreSQL e implementação do pipeline (sequência de etapas automáticas) de RAG com LangChain e ChromaDB. A validação interna consiste em gerar questões para três materiais didáticos de disciplinas diferentes — a diversidade verifica se a qualidade da geração se mantém em conteúdos heterogêneos — com inspeção manual pelo autor e revisão pelo orientador.

5.3 Etapa 3 — Interface e visão computacional

Desenvolvimento da interface em Angular e integração do Face Mesh e do YOLOv8-nano via ONNX Runtime Web, incluindo o teste de viabilidade de *hardware* e a degradação graciosa descritos no Capítulo 4. Os limiares de EAR e de posição da cabeça são calibrados em um piloto interno com voluntários informais, usado apenas para ajuste de parâmetros, sem fins científicos.

5.4 Etapa 4 — Avaliação experimental

Execução do protocolo descrito no Capítulo 6, condicionada à aprovação do CEP-PUCRS. A coleta ocorre fora do horário de aula, no ambiente doméstico do estudante, com sessões guiadas remotamente.

6. AVALIAÇÃO

6.1 Considerações éticas

Por envolver coleta de dados com seres humanos — com uso de câmera, ainda que o processamento ocorra localmente, sem envio de vídeo ao servidor — o projeto será submetido ao Comitê de Ética em Pesquisa da PUCRS (CEP-PUCRS), via Plataforma Brasil (o sistema federal de registro de pesquisas com seres humanos), antes de qualquer coleta. Estão previstos: o protocolo de pesquisa, o Termo de Consentimento Livre e Esclarecido (TCLE — documento que explica a pesquisa em linguagem acessível e que o participante assina confirmando sua adesão voluntária), a descrição técnica das medidas de proteção dos dados (nenhum vídeo é transmitido; apenas métricas numéricas agregadas são armazenadas) e o plano de descarte dos dados ao final do projeto. A aprovação do CEP é condição necessária para iniciar a Etapa 4 da metodologia.

6.2 Desenho experimental

Cada participante realizará duas sessões de estudo na plataforma. Na condição de controle, lê o material sem questões formativas; na condição de intervenção, lê material equivalente — com a mesma extensão e nível de dificuldade — com questões inseridas nos pontos de verificação. Em ambas, o monitoramento visual permanece ativo.

Esse desenho, em que cada participante serve como seu próprio grupo de comparação (chamado de *intra-sujeitos* ou *within-subjects*), foi escolhido porque aumenta a sensibilidade estatística quando o número de participantes é pequeno: ao comparar a mesma pessoa nas duas condições, elimina-se a variabilidade natural entre indivíduos diferentes, e qualquer diferença observada pode ser atribuída à intervenção em si [WRH⁺12]. A ordem das condições será sorteada para cada participante, evitando que a ordem de apresentação influencie os resultados (efeitos de ordem e fadiga). As sessões serão separadas por pelo menos 24 horas — intervalo adotado para reduzir a contaminação entre as condições, prática usual em estudos desse tipo [WRH⁺12] — e terão duração de 30 a 40 minutos, compatível com a leitura de um capítulo de material didático.

6.3 Participantes

Serão recrutados de 12 a 18 estudantes voluntários de Ciência da Computação ou áreas afins da PUCRS, maiores de 18 anos, com acesso a um notebook com câmera. O intervalo considera: (i) o caráter exploratório do estudo (busca de evidências iniciais, não de conclusões definitivas); (ii) a literatura de testes de usabilidade, que indica que o retorno marginal de cada novo participante decresce após cerca de 15 pessoas, pois a maioria dos problemas relevantes já terá sido identificada [Nie00]; e (iii) a variação de *hardware*, que tende a reduzir o número de sessões válidas para a QP2 (participantes com computadores mais lentos entrarão em modo degradado e não serão contabilizados nessa questão específica).

6.4 Indicadores

Três indicadores quantitativos são extraídos automaticamente pela plataforma.

`focusScore` (**pontuação de foco**): proporção do tempo da sessão em que o rosto está detectado, a cabeça está voltada para a tela e o EAR indica olhos abertos acima do limiar individual (Capítulo 4).

`phoneDetectedEvents` (**eventos de celular**): número de intervalos da sessão em que o celular foi detectado em pelo menos k quadros consecutivos (imagens capturadas em sequência). A exigência de múltiplos quadros consecutivos filtra detecções espúrias isoladas, como sombras ou reflexos que possam enganar o modelo por um único instante; o valor de k será calibrado no piloto interno. O indicador se aplica apenas a sessões fora do modo degradado.

`accuracyRate` (**taxa de acerto**): proporção de questões respondidas corretamente na condição de intervenção. Cada questão é revisada pelo autor e pelo orientador antes das sessões, garantindo que o gabarito está correto.

Adicionalmente, ao final do experimento, cada participante responde ao questionário SUS [Bro96], interpretado conforme a Seção 3.2.

6.5 Análise estatística

Com 12 a 18 participantes, a amostra fica abaixo de cerca de 30 observações — o patamar a partir do qual se pode, com alguma segurança, supor que os dados seguem uma distribuição normal (a curva em sino que muitos fenômenos naturais obedecem) [Fie13].

Abaixo desse patamar, não se pode fazer essa suposição, e por isso adotam-se testes *não-paramétricos*: testes estatísticos que funcionam independentemente da distribuição dos dados.

Para a QP1 (atenção e desempenho): calcula-se a correlação de Spearman (ρ — a letra grega “rho”, que representa a força e a direção da relação entre duas variáveis ordenadas) entre `focusScore` e `accuracyRate` nas sessões de intervenção. Esse teste é adequado porque detecta associações monotônicas (à medida que uma variável sobe, a outra também tende a subir ou descer) sem exigir distribuição normal. Reportam-se ρ , o p -valor (a probabilidade de o resultado ter ocorrido por acaso, sendo que valores abaixo de 0,05 são convencionalmente interpretados como evidência de associação real) e o intervalo de confiança calculado por *bootstrap* (uma técnica de reamostragem dos próprios dados para estimar a margem de erro sem depender de fórmulas matemáticas específicas).

Para a QP2 (intervenção e dispersão): aplica-se o teste de Wilcoxon dos postos sinalizados (versão pareada, adequada ao desenho intra-sujeitos), comparando `phoneDetectedEvents` de cada participante nas duas condições. Reportam-se a estatística W , o p -valor e o tamanho do efeito $r = Z/\sqrt{N}$ (uma medida de quão grande é a diferença observada, em escala padronizada).

Para a QP3 (usabilidade): reportam-se a média, a mediana e o intervalo de confiança de 95% por *bootstrap* das pontuações SUS, comparados ao limiar de 68 justificado na Seção 3.2.

Os resultados serão acompanhados da ressalva de que o estudo tem caráter exploratório: o objetivo é gerar evidências iniciais de viabilidade, não conclusões generalizáveis para toda a população.

6.6 Avaliação do painel pelo docente

Em paralelo à avaliação com alunos, o painel analítico é avaliado qualitativamente com três professores — quantidade mínima recomendada para inspeções de usabilidade, nas quais três a cinco avaliadores já são capazes de identificar a maior parte dos problemas [Nie94]. A avaliação combina: inspeção heurística (análise por especialistas guiada por uma lista de critérios de boa usabilidade) segundo as heurísticas de Nielsen [Nie94]; entrevista semiestruturada (conversa com roteiro parcialmente fixo, que permite aprofundar temas surgidos durante o diálogo) com cada docente, após o uso do painel com dados reais anonimizados; e análise de conteúdo das entrevistas segundo Bardin [Bar11] (método de leitura sistemática de textos para identificar padrões e categorias de resposta). Essa etapa permite saber se o painel é, de fato, útil para o professor do ponto de vista pedagógico.

6.7 Riscos e mitigações

A Tabela 6.1 sintetiza os principais riscos do projeto.

Table 6.1 – Principais riscos do projeto e mitigações previstas.

Risco	Impacto	Mitigação
Atraso na aprovação CEP	Bloqueio da Etapa 4	Submissão no início de TC2; durante a espera, refinamento da implementação e piloto interno sem coleta científica.
Computador do voluntário não suporta o detector de celular	Redução do número útil de participantes para a QP2	Modo degradado já previsto; recrutamento de 30% a mais que o mínimo, para compensar perdas por limitação de equipamento e desistências.
Modelo de IA gera questões de baixa qualidade	Compromete a taxa de acerto	Revisão humana obrigatória antes das sessões; instrução ao modelo com formato fixo e verificação de aderência ao trecho-fonte.
Custo elevado das chamadas a LLMs comerciais	Inviabilidade econômica	Geração restrita à fase de preparação, com reutilização do banco de questões pré-geradas durante as sessões.
Desistência de participantes entre as duas sessões	Quebra do pareamento entre as condições	Agendamento das duas sessões no ato do recrutamento; lembretes automáticos.

7. CRONOGRAMA

As atividades de TC1 — definição do problema, revisão de literatura e redação desta proposta — foram concluídas no semestre 2026/1. A Tabela 7.1 apresenta o cronograma de TC2.

Table 7.1 – Cronograma de TC2 (2026/2).

Atividade	Ago	Set	Out	Nov	Dez
Submissão ao CEP-PUCRS	X				
Implementação servidor e geração de questões	X	X			
Implementação interface e visão computacional	X	X	X		
Piloto interno e calibração		X	X		
Experimento com voluntários			X	X	
Inspeção e entrevistas com docentes				X	
Análise estatística e qualitativa				X	
Redação final do TCC			X	X	X
Defesa de TC2					X

7.1 Marcos de decisão

- **Fim de setembro/2026:** servidor e geração de questões funcionais, com questões validadas em três materiais distintos. Se não for possível, o cenário Expandido é simplificado.
- **Fim de outubro/2026:** interface e análise facial estáveis e teste do detector de celular concluído. Se poucos alunos tiverem hardware compatível, a QP2 é reportada como inconclusiva e a avaliação se concentra nas QP1 e QP3.
- **Aprovação do CEP:** havendo atraso, a Etapa 4 avança em modo de piloto interno, sem coleta científica, enquanto a inspeção com docentes segue normalmente.

8. CONSIDERAÇÕES FINAIS

Esta proposta reúne, em uma única plataforma acessada pelo navegador, três iniciativas integradas: geração automática de questões formativas a partir do material do professor, monitoramento local da atenção visual do estudante e um painel analítico para o docente. O tratamento da privacidade é uma decisão de arquitetura — nenhum vídeo do aluno trafega pela rede — e não apenas uma política declarada.

As principais restrições técnicas são reconhecidas desde o início e têm resposta definida: quando o computador do aluno não suporta o detector de celular, o sistema continua funcionando apenas com a análise facial, registrando o modo de operação para que a análise estatística leve isso em conta.

A avaliação combina testes estatísticos adequados ao tamanho previsto da amostra com métodos qualitativos junto a professores, e está condicionada à aprovação do Comitê de Ética em Pesquisa. Ao final do trabalho, espera-se contribuir com três resultados: (i) evidência preliminar sobre a relação entre atenção visual e desempenho em questões geradas por IA; (ii) uma análise fundamentada sobre os limites práticos de rodar modelos de inteligência artificial no navegador, com privacidade preservada; e (iii) um protótipo funcional que sirva de base para trabalhos futuros em ambientes virtuais de aprendizagem inteligentes.

REFERENCES

- [AK24] Abedi, A.; Khan, S. S. “Engagement measurement based on facial landmarks and spatial-temporal graph convolutional networks”. Source: <https://arxiv.org/abs/2403.17175>, Mai 2026.
- [Bar11] Bardin, L. “Análise de Conteúdo”. São Paulo, SP, Brasil: Edições 70, 2011.
- [Bat19] Bates, A. W. T. “Teaching in a Digital Age: Guidelines for Designing Teaching and Learning”. Vancouver, BC: Tony Bates Associates Ltd., 2019, second ed..
- [BKM08] Bangor, A.; Kortum, P. T.; Miller, J. T. “An empirical evaluation of the system usability scale”, *International Journal of Human–Computer Interaction*, vol. 24–6, 2008, pp. 574–594.
- [BMR+20] Brown, T. B.; Mann, B.; Ryder, N.; Subbiah, M.; Kaplan, J.; Dhariwal, P.; Neelakantan, A.; Shyam, P.; Sastry, G.; Askell, A.; et al.. “Language models are few-shot learners”. In: *Advances in Neural Information Processing Systems*, 2020, pp. 1877–1901.
- [Bra18] Brasil. “Lei n. 13.709, de 14 de agosto de 2018. lei geral de proteção de dados pessoais (LGPD)”. Source: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm, Mai 2026.
- [Bro96] Brooke, J. “SUS – a quick and dirty usability scale”. In: *Usability Evaluation in Industry*, Jordan, P. W.; Thomas, B.; Weerdmeester, B. A.; McClelland, A. L. (Editors), London: Taylor & Francis, 1996, chap. 21, pp. 189–194.
- [Cav09] Cavoukian, A. “Privacy by design: The 7 foundational principles”, Technical Report, Information and Privacy Commissioner of Ontario, Toronto, Canada, 2009.
- [Coh88] Cohen, J. “Statistical Power Analysis for the Behavioral Sciences”. Hillsdale, NJ, USA: Lawrence Erlbaum Associates, 1988, second ed..
- [DD25] Das, R.; Dev, S. “Optimizing student engagement detection using facial and behavioral features”, *Neural Computing and Applications*, vol. 37–23, 2025, pp. 19063–19085.
- [DDD17] D’Mello, S.; Dieterle, E.; Duckworth, A. “Advanced, analytic, automated (AAA) measurement of engagement during learning”, *Educational Psychologist*, vol. 52–2, 2017, pp. 104–123.

- [Fie13] Field, A. "Discovering Statistics Using IBM SPSS Statistics". London, UK: SAGE Publications Ltd., 2013, fourth ed..
- [Fla79] Flavell, J. H. "Metacognition and cognitive monitoring: A new area of cognitive-developmental inquiry", *American Psychologist*, vol. 34–10, 1979, pp. 906–911.
- [GXG⁺23] Gao, Y.; Xiong, Y.; Gao, X.; Jia, K.; Pan, J.; Bi, Y.; Dai, Y.; Sun, J.; Wang, M.; Wang, H. "Retrieval-augmented generation for large language models: A survey". Source: <https://arxiv.org/abs/2312.10997>, Mai 2026.
- [HBF19] Holmes, W.; Bialik, M.; Fadel, C. "Artificial Intelligence in Education: Promises and Implications for Teaching and Learning". Boston, MA, USA: Center for Curriculum Redesign, 2019.
- [JCQ23] Jocher, G.; Chaurasia, A.; Qiu, J. "Ultralytics YOLOv8". Source: <https://github.com/ultralytics/ultralytics>, Mai 2026.
- [KAGG19] Kartynnik, Y.; Ablavatski, A.; Grishchenko, I.; Grundmann, M. "Real-time facial surface geometry from monocular video on mobile GPUs". Source: <https://arxiv.org/abs/1907.06724>, Mai 2026.
- [KDB17] Kirschner, P. A.; De Bruyckere, P. "The myths of the digital native and the multitasker", *Teaching and Teacher Education*, vol. 67, 2017, pp. 135–142.
- [LPP⁺20] Lewis, P.; Perez, E.; Piktus, A.; Petroni, F.; Karpukhin, V.; Goyal, N.; Küttler, H.; Lewis, M.; Yih, W.-t.; Rocktäschel, T.; Riedel, S.; Kiela, D. "Retrieval-augmented generation for knowledge-intensive NLP tasks". In: *Advances in Neural Information Processing Systems*, 2020, pp. 9459–9474.
- [LTN⁺19] Lugaresi, C.; Tang, J.; Nash, H.; McClanahan, C.; Uboweja, E.; Hays, M.; Zhang, F.; Chang, C.-L.; Yong, M. G.; Lee, J.; et al.. "MediaPipe: A framework for building perception pipelines". Source: <https://arxiv.org/abs/1906.08172>, Mai 2026.
- [MdCMSL20] Maior, C. B. S.; das Chagas Moura, M. J.; Santana, J. M. M.; Lins, I. D. "Real-time classification for autonomous drowsiness detection using eye aspect ratio", *Expert Systems with Applications*, vol. 158, 2020, pp. 113505.
- [Nie93] Nielsen, J. "Usability Engineering". San Francisco, CA, USA: Morgan Kaufmann, 1993.
- [Nie94] Nielsen, J. "Heuristic evaluation". In: *Usability Inspection Methods*, Nielsen, J.; Mack, R. L. (Editors), New York, NY, USA: John Wiley & Sons, Inc., 1994, chap. 2, pp. 25–62.

- [Nie00] Nielsen, J. “Why you only need to test with 5 users”. Source: <https://www.nngroup.com/articles/why-you-only-need-to-test-with-5-users/>, Mai 2026.
- [RDGF16] Redmon, J.; Divvala, S.; Girshick, R.; Farhadi, A. “You only look once: Unified, real-time object detection”. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 779–788.
- [Sau11] Sauro, J. “A Practical Guide to the System Usability Scale”. Denver, CO, USA: Measuring Usability LLC, 2011.
- [SC16] Soukupová, T.; Cech, J. “Real-time eye blink detection using facial landmarks”. In: 21st Computer Vision Winter Workshop, 2016, pp. 1–8.
- [UNE21] UNESCO. “AI and education: Guidance for policy-makers”, Technical Report, UNESCO, Paris, France, 2021.
- [Van11] VanLehn, K. “The relative effectiveness of human tutoring, intelligent tutoring systems, and other tutoring systems”, *Educational Psychologist*, vol. 46–4, 2011, pp. 197–221.
- [WRH⁺12] Wohlin, C.; Runeson, P.; Höst, M.; Ohlsson, M. C.; Regnell, B.; Wesslén, A. “Experimentation in Software Engineering”. Berlin, Heidelberg: Springer-Verlag, 2012.
- [ZZL⁺23] Zhao, W. X.; Zhou, K.; Li, J.; Tang, T.; Wang, X.; Hou, Y.; Min, Y.; Zhang, B.; Zhang, J.; Dong, Z.; et al.. “A survey of large language models”. Source: <https://arxiv.org/abs/2303.18223>, Mai 2026.